



Fut Analytics

Inteligência de Dados para o Futebol

Matheus Manfron Espinoza



Fut Analitics

Previsão de resultados de partidas de futebol com Machine Learning

KNN • Scottish Premiership • SportMonks

- Problema: classificar o resultado do ponto de vista de um time — derrota, empate ou vitória.
- Base final: 3.446 linhas; 3.356 após remover 90 partidas sem histórico.
- Modelo final: KNN com seleção de hiperparâmetros por validação temporal.

FALA: O objetivo é prever o resultado de uma partida usando apenas informações disponíveis antes dela.

1. Evolução desde a AP1

O projeto ganhou escala e passou a priorizar rigor temporal

AP1

AP2

- Escopo inicial: poucas equipes e histórico reduzido.
- Evolução: base ampliada para 12 times, com partidas de 2014 a 2026.
- A abordagem foi consolidada como classificação supervisionada.
- Decisão importante: usar divisão temporal para simular o cenário real — treinar no passado e testar no futuro.
- O tratamento passou a usar somente informações anteriores à partida, evitando vazamento.

FALA: A principal mudança foi sair de um protótipo pequeno para uma base maior e uma avaliação mais próxima do uso real.

2. Preparação dos dados

A base foi construída para representar somente o histórico disponível antes de cada jogo

3.446 linhas

3.356 linhas

90 removidas

11 atributos

- Foram removidas 90 linhas sem histórico suficiente para calcular as variáveis de forma.
- As variáveis foram calculadas com médias móveis e shift(1): o jogo atual não entra no cálculo.
- Foram eliminadas duplicatas reais: 0 linhas duplicadas; a visão espelhada de uma mesma partida não é considerada duplicata.
- Atributos principais: mando, pontos, gols, escanteios, posse, cartões, desempenho do adversário e diferença de pontos.

FALA: Um detalhe importante: uma partida pode aparecer em duas linhas, uma para cada time. Isso é uma representação do ponto de vista de cada equipe, não uma duplicação.

3. Modelo escolhido

KNN: vizinhos semelhantes para classificar o resultado

StandardScaler + KNN

- KNeighborsClassifier com $k = 35$, distância euclidiana ($p=2$) e pesos uniformes.
- O KNN foi escolhido por GridSearchCV usando TimeSeriesSplit(5), somente dentro do treino.
- O StandardScaler é necessário porque o KNN depende de distância entre observações.
- Alternativa considerada: Lógica Fuzzy. O KNN foi usado como primeiro modelo por transformar diretamente os padrões históricos em classes de resultado.

FALA: A característica mais importante é que KNN compara uma partida com outras partidas de perfil estatístico semelhante. Como usa distância, a padronização das variáveis é essencial.

4. Processo de treinamento

Divisão temporal + validação temporal

Treino: 2.686 linhas
até 04/12/2024

Teste: 670 linhas
07/12/2024–17/05/2026

TimeSeriesSplit(5)

- A separação foi cronológica, não aleatória, para evitar usar informação futura no treinamento.
- O GridSearchCV escolheu $k=35$ usando somente o conjunto de treino.
- O scaler também está dentro do pipeline e é ajustado sem olhar a base inteira.
- Baseline 1: classe mais frequente. Baseline 2: mando — casa vence, fora perde.

FALA: O baseline responde à pergunta: o modelo realmente aprendeu algo ou apenas repete uma regra simples?

5. Métricas e resultado

F1 macro é a métrica principal porque as três classes precisam ser consideradas

F1 macro = 0,411

Acurácia = 0,500

CV temporal = 0,533

Real \ Prev.	Derrota	Empate	Vitória
Derrota	151	22	70
Empate	66	9	82
Vitória	81	14	175

- Derrota: F1 0,56 | Vitória: F1 0,59 | Empate: F1 0,09.
- O modelo acertou 335 de 670 casos.
- Principal problema: 148 dos 157 empates reais não foram identificados.

FALA: A acurácia de 50% parece razoável, mas o F1 macro revela o problema: o modelo praticamente não reconhece empates.

5. Comparação com o baseline

O KNN melhora, mas o ganho sobre o baseline de mando é modesto

Métrica	Mais frequente	Mando	KNN
Acurácia	0,403	0,467	0,500
F1 macro	0,191	0,353	0,411
Recall empate	0,000	0,000	0,057

- +9,7 p.p. de acurácia vs. classe mais frequente.
- +3,3 p.p. de acurácia vs. baseline do mando.
- F1 macro: +0,220 vs. mais frequente e +0,058 vs. mando.
- O ganho contra o baseline do mando deve ser tratado como melhora modesta; o teste tem margem de erro de cerca de $\pm 3,8$ p.p.

FALA: O resultado mais seguro é dizer que o KNN supera os dois baselines, mas não exagerar o ganho de acurácia sobre a regra de mando.

6. Erros e limitações

O principal desafio é separar o empate de vitória e derrota

Empate real → vitória: 82

Vitória real → derrota: 81

Derrota real → vitória: 70

- Falso positivo de vitória: 152 casos — o modelo promete vitória, mas ocorre empate ou derrota.
- Falso negativo de vitória: 95 casos — o time vence, mas o modelo prevê empate ou derrota.
- Limitação central: os atributos atuais capturam forma recente, mas não isolam bem jogos equilibrados.
- Há leve sinal de underfitting: treino 0,549 vs. teste 0,500; F1 macro 0,466 vs. 0,411. Não há overfitting relevante.

FALA: O modelo não está decorando os dados. O problema é o contrário: as variáveis ainda não têm informação suficiente para separar os três resultados.

7. Próximos passos para a AS

Transformar o protótipo em um modelo mais robusto

- Melhorar a identificação de empates usando `predict_proba` e um critério específico para jogos equilibrados.
- Adicionar atributos de equilíbrio, como a diferença absoluta de pontos entre os times.
- Comparar KNN com outros modelos de classificação.
- Testar novas formas de balanceamento das classes e avaliar o impacto no F1 macro.
- Ampliar a engenharia de atributos: forma recente, mando, desempenho do adversário e outras estatísticas disponíveis.
- Manter a divisão temporal e os cuidados contra vazamento.

Meta: melhorar principalmente o F1 da classe empate

FALA: Para a AS, o objetivo principal não é apenas aumentar a acurácia, mas fazer o modelo reconhecer melhor as três classes.